

Ultra-Short PPG Dynamics Across the Wakefulness-to-Drowsiness Transition: A Nonlinear Time-Series Analysis

Vu Trinh Tu*, Thang Manh Hoang*[†]

* School of Electrical and Electronic Engineering, Hanoi University of Science and Technology, Hanoi, Vietnam
Tu.VT261032M@sis.hust.edu.vn, thang.hoangmanh@hust.edu.vn

[†]Corresponding author

Abstract—Photoplethysmography (PPG) has been widely used for drowsiness monitoring, yet most existing studies treat it primarily as a source of conventional physiological features or as input to classification models, leaving the dynamical reorganization of the signal during the Awake–Drowsy transition insufficiently characterized. This study investigates ultra-short PPG dynamics using complementary nonlinear time-series analysis methods, including Simplex Projection, Recurrence Quantification Analysis (RQA), and the Largest Lyapunov Exponent (LLE). Twenty recording sessions from 10 healthy young adults were analyzed, with 60-s non-overlapping windows used as the primary configuration and 30, 120, and 180 s windows used for robustness analysis. Pseudoperiodic surrogate testing showed that both Awake and Drowsy PPG contained temporal organization beyond that reproduced by a noisy pseudoperiodic null model, without implying deterministic chaos. In the primary 60-s analysis, Drowsiness was associated with reduced forecastability ($\Delta CC = -0.0339$, $q_{BH} = 0.0376$; $\Delta NRMSE = +0.0294$, $q_{BH} = 0.0255$), reduced diagonal recurrence organization ($\Delta DET = -0.0186$, $q_{BH} = 0.0376$), and reduced local trajectory divergence ($\Delta LLE = -0.0376 \text{ s}^{-1}$, $q_{BH} = 0.0050$). These directions were preserved across 30–180 s windows, although uncertainty increased at 30 s. Overall, the Awake–Drowsy transition was characterized by coordinated changes in several complementary dynamical properties of PPG rather than by a simple shift along a single “more chaos”–“less chaos” axis. These findings provide a dynamical characterization of short-window PPG during declining vigilance and support the future development of nonlinear descriptors for wearable drowsiness monitoring.

Index Terms—Photoplethysmography, drowsiness, NTSA, recurrence quantification analysis, nonlinear prediction, largest Lyapunov exponent, symbolic analysis, PPS

I. INTRODUCTION

Buồn ngủ (*drowsiness*) là một quá trình chuyển tiếp sinh lý diễn ra dần dần từ trạng thái tỉnh táo về phía giấc ngủ, đi kèm với sự suy giảm mức độ tỉnh táo, khả năng duy trì chú ý và phản ứng với các kích thích bên ngoài [1]–[3]. Quá trình này đồng thời liên quan đến những thay đổi trong điều hòa của hệ thần kinh tự chủ (autonomic nervous system, ANS), bao gồm các biến đổi về nhịp tim, huyết áp, hô hấp và hoạt động tim mạch [2]. Vì phản ánh trực tiếp hơn những thay đổi sinh lý bên trong cơ thể, các tín hiệu như EEG, ECG, EOG, EMG và PPG đã được sử dụng rộng rãi trong các hệ thống phát hiện buồn ngủ, bên cạnh các phương pháp dựa trên hành vi hoặc thông số vận hành phương tiện [1]–[3]. Trong

số đó, photoplethysmography (PPG) là một lựa chọn đặc biệt hấp dẫn nhờ tính không xâm lấn, chi phí thấp và khả năng tích hợp vào các thiết bị đeo hoặc các nền tảng giám sát liên tục. Nhiều nghiên cứu đã khai thác PPG hoặc các đại lượng suy ra từ PPG để phát hiện buồn ngủ, chủ yếu thông qua các đặc trưng như heart rate (HR), heart-rate variability (HRV), SDNN, RMSSD, LF, HF, LF/HF, pulse arrival time hoặc các đặc trưng hình thái và miền thời gian–tần số, sau đó kết hợp với các mô hình machine learning hoặc deep learning để thực hiện detection/classification [4]–[8]. Tuy nhiên, PPG không chỉ là một nguồn cung cấp các đặc trưng thống kê đơn lẻ; tín hiệu này còn thể hiện tổ chức động lực học phi tuyến, pseudoperiodic và có cấu trúc phức tạp theo thời gian [9], [10]. Vì vậy, việc chỉ khai thác các đặc trưng truyền thống có thể chưa mô tả đầy đủ cách động lực học của PPG thay đổi khi trạng thái sinh lý chuyển từ Awake sang Drowsy.

Mặc dù nonlinear time-series analysis (NTSA) đã được ứng dụng rộng rãi trong nhiều loại tín hiệu sinh lý, các phân tích động lực học trực tiếp trên PPG vẫn còn tương đối hạn chế so với các ứng dụng truyền thống của tín hiệu này [11]. Một số nghiên cứu đã khai thác phase-space reconstruction, Poincaré analysis, recurrence-based representations hoặc các đặc trưng phi tuyến của PPG cho các bài toán như ước lượng huyết áp, nhận dạng cảm xúc và đánh giá bệnh lý tim mạch [12]–[15]. Trong drowsiness detection, các biểu diễn phi tuyến cũng đã xuất hiện, nhưng thường được sử dụng như một bước feature transformation trước khi đưa vào mô hình phân loại. Chẳng hạn, Lee *et al.* chuyển các chuỗi RRI thu từ ECG và PPG thành các recurrence plots rồi sử dụng CNN để phân loại Awake và Drowsy [16]. Cách tiếp cận này cho thấy giá trị dự báo của các biểu diễn động lực học, nhưng mục tiêu chính vẫn là classification thay vì giải thích sự thay đổi của bản thân hệ động lực học. Đồng thời, mặc dù các nghiên cứu HRV và ECG cho thấy drowsiness đi kèm với những thay đổi của cardiovascular/autonomic regulation [2], [6], mối liên hệ giữa các thay đổi sinh lý này và sự tái tổ chức động lực học của PPG vẫn chưa được đặc trưng một cách có hệ thống. Do đó, cần một cách tiếp cận tập trung trực tiếp vào quá trình Awake–Drowsy transition và mô tả cách nhiều khía cạnh khác nhau của PPG dynamics thay đổi theo trạng thái, thay vì chỉ sử dụng chúng như các đầu vào cho một bộ phân loại.

Một vấn đề quan trọng khác đối với cả drowsiness monitor-

ing và nonlinear analysis là độ dài cửa sổ quan sát. Trong phân tích HRV, các khái niệm short-term và ultra-short-term (UST) đã được phát triển nhằm giảm thời gian ghi tín hiệu trong khi vẫn duy trì khả năng ước lượng một số đặc trưng sinh lý [17], [18]. Các nghiên cứu drowsiness và physiological monitoring hiện cũng sử dụng những temporal windows rất khác nhau, từ vài giây hoặc 30 s đến 1–5 min hoặc dài hơn [19]–[23]. Việc lựa chọn cửa sổ tạo ra một trade-off quan trọng: cửa sổ ngắn cho phép tăng temporal resolution, giảm độ trễ và thuận lợi hơn cho các ứng dụng wearable hoặc near-real-time, nhưng đồng thời cung cấp ít dữ liệu hơn để mô tả đầy đủ cấu trúc sinh lý của tín hiệu. Thách thức này đặc biệt đáng chú ý đối với NTSA. Cửa sổ ngắn có thể cải thiện tính dừng cục bộ của tín hiệu, nhưng đồng thời làm giảm số lượng điểm trong reconstructed state space, số recurrence structures và số trajectory pairs khả dụng, từ đó làm tăng độ bất định của các dynamical estimates. Mặc dù một số nghiên cứu đã khảo sát độ tin cậy của các đặc trưng HRV trên các cửa sổ ultra-short [24], sự phụ thuộc của các đặc trưng nonlinear dynamics của PPG vào window length vẫn ít được nghiên cứu một cách có hệ thống.

Các nghiên cứu của Sviridova và cộng sự cung cấp một nền tảng quan trọng cho việc xem PPG như một hệ động lực học thay vì chỉ là một nguồn feature. Sviridova *et al.* (2015) sử dụng nhiều phương pháp nonlinear time-series analysis để cho thấy PPG chứa các cấu trúc động lực học phi tuyến và các đặc tính của một hệ hỗn loạn, đồng thời nhấn mạnh rằng việc đánh giá một tín hiệu sinh lý phức tạp không nên dựa trên một chỉ số đơn lẻ [10]. Tiếp đó, Sviridova *et al.* (2018) sử dụng pseudoperiodic surrogate (PPS) testing để kiểm tra liệu tổ chức động lực học quan sát được trong PPG có thể được giải thích chỉ bởi một noisy pseudoperiodic process hay không, qua đó cung cấp một null model phù hợp hơn cho tín hiệu có tính dao động tuần hoàn mạnh như PPG [25]. Gần đây hơn, Sviridova *et al.* (2022) khảo sát ảnh hưởng của recording length đối với recurrence-based analysis và cho thấy thông tin động lực học hữu ích vẫn có thể được trích xuất từ các đoạn PPG tương đối ngắn, mặc dù độ chính xác của các estimate phụ thuộc vào metric và độ dài dữ liệu [26]. Các nghiên cứu này thiết lập ba nền tảng quan trọng: PPG chứa tổ chức động lực học phi tuyến, pseudoperiodicity phải được kiểm soát khi kiểm định các đặc tính đó, và short-recording analysis có tiềm năng thực hiện được. Tuy nhiên, chúng chủ yếu đặc trưng hóa PPG trong từng điều kiện riêng biệt và chưa tập trung vào cách nhiều đặc tính động lực học thay đổi đồng thời trong quá trình chuyển từ Awake sang Drowsy, cũng như mức độ bền vững của các thay đổi đó trên nhiều độ dài cửa sổ.

Xuất phát từ những khoảng trống trên, nghiên cứu này đề xuất một framework nonlinear time-series analysis để đặc trưng hóa PPG trong quá trình chuyển từ Awake sang Drowsy ở các cửa sổ thời gian siêu ngắn. Thay vì xem PPG dynamics thông qua một chỉ số chaos đơn lẻ, framework kết hợp ba góc nhìn bổ sung: nonlinear prediction để đánh giá short-term forecastability, Recurrence Quantification Analysis (RQA) để mô tả recurrence organization, và Largest Lyapunov Exponent (LLE) để định lượng local trajectory divergence. Nghiên cứu

tập trung vào hai câu hỏi chính: (1) liệu các đoạn PPG ngắn ở cả trạng thái Awake và Drowsy có chứa tổ chức động lực học vượt quá những gì có thể được giải thích bởi một noisy pseudoperiodic process hay không; và (2) forecastability, recurrence organization và local trajectory divergence thay đổi như thế nào khi trạng thái chuyển từ Awake sang Drowsy. Pseudoperiodic surrogate testing được sử dụng để kiểm định nền tảng động lực học, trong khi phân tích trên nhiều window lengths được thực hiện để đánh giá mức độ bền vững của các kết quả ở thang thời gian siêu ngắn. Bên cạnh việc cung cấp một mô tả động lực học chi tiết hơn về Awake–Drowsy transition, các kết quả này có thể tạo cơ sở cho việc phát triển các nonlinear dynamical features trong các hệ thống PPG-based drowsiness monitoring tương lai.

II. MATERIALS AND METHODS

A. Dataset and Experimental Protocol

Nghiên cứu sử dụng 20 phiên ghi PPG từ 10 tình nguyện viên trẻ khỏe mạnh (6 nam, 4 nữ; tuổi trung bình 21.8 ± 1.2 năm). Dữ liệu được thu bằng cảm biến MAX30102 kết hợp với ESP32 trong các phiên ghi sau bữa ăn, nhằm quan sát trạng thái buồn ngủ xuất hiện tự nhiên trong giai đoạn suy giảm tỉnh táo hậu thực phẩm. Trạng thái của người tham gia được gán nhãn dựa trên video theo dõi kết hợp với Karolinska Sleepiness Scale (KSS) [27], trong đó KSS được sử dụng như thước đo chủ quan chính của mức độ buồn ngủ. Sau bước kiểm tra và loại bỏ các phiên không đáp ứng yêu cầu phân tích, 20 phiên được giữ lại, với tổng thời lượng 17.40 giờ PPG, gồm 11.33 giờ Awake (65.35%) và 6.07 giờ Drowsy (34.65%). Thiết kế này cho phép phân tích trực tiếp sự thay đổi của động lực học PPG giữa hai trạng thái Awake và Drowsy trong điều kiện buồn ngủ tự nhiên.

B. PPG Preprocessing

Tín hiệu PPG thô được tiền xử lý bằng bộ lọc Butterworth thông dải bậc hai với dải tần 0.5–8 Hz. Bộ lọc được áp dụng theo hai chiều để đạt đáp ứng zero-phase, qua đó hạn chế sai lệch pha của dạng sóng PPG. Ngưỡng thấp 0.5 Hz được sử dụng để làm suy giảm thành phần trôi đường nền và các biến thiên rất chậm, trong khi ngưỡng 8 Hz giúp giảm nhiễu cao tần nhưng vẫn giữ lại dải dao động chính của tín hiệu PPG. Như minh họa trong Fig. 1, quá trình lọc làm suy giảm rõ rệt thành phần baseline drift trong khi vẫn bảo toàn cấu trúc chu kỳ và hình thái chính của dạng sóng. Tín hiệu sau lọc được sử dụng làm đầu vào cho các bước phân đoạn, kiểm soát chất lượng và phân tích chuỗi thời gian phi tuyến tiếp theo.

C. Awake–Drowsy Segmentation and Quality Control

Sau bước tiền xử lý, các đoạn tín hiệu tương ứng với hai trạng thái Awake và Drowsy được phân tách độc lập trong từng session và tiếp tục chia thành các cửa sổ không chồng lấp để phục vụ phân tích chuỗi thời gian phi tuyến. Việc sử dụng các cửa sổ hữu hạn nhằm tăng mức độ quasi-stationary của tín hiệu trong mỗi đoạn phân tích, đồng thời cho phép đánh giá động lực học PPG trên các thang thời gian ngắn. Cửa sổ 60 s được lựa chọn làm cấu hình chính, trong khi các cửa sổ




Fig. 1: Minh họa tín hiệu PPG trước và sau tiền xử lý. (A) Tín hiệu PPG thô với thành phần trôi đường nền rõ rệt. (B) Tín hiệu tương ứng sau khi áp dụng bộ lọc Butterworth thông dải bậc hai, zero-phase, trong dải 0.5–8 Hz. Quá trình lọc làm suy giảm biến thiên nền chậm trong khi vẫn duy trì hình thái chính của các chu kỳ PPG.

30, 120 và 180 s được sử dụng cho phân tích robustness theo độ dài cửa sổ. Mỗi cửa sổ sau phân đoạn được đánh giá theo hai lớp kiểm soát chất lượng. Thứ nhất, signal quality index (SQI) được sử dụng để phát hiện và loại bỏ các cửa sổ có biên độ đỉnh bất thường hoặc chất lượng dạng sóng không phù hợp cho phân tích tiếp theo. Thứ hai, tính quasi-stationary được đánh giá dựa trên độ ổn định của phương sai trong cửa sổ. Chỉ các cửa sổ đồng thời đạt tiêu chí SQI và quasi-stationarity mới được giữ lại cho các bước tái dựng không gian pha và phân tích NTSA. Quy trình tổng quát được thực hiện theo thứ tự: segmentation → SQI assessment → quasi-stationarity validation → valid-window retention → nonlinear time-series analysis.

Tỷ lệ các cửa sổ vượt qua bước kiểm soát chất lượng được trình bày trong Table I. Nhìn chung, phần lớn các cửa sổ ở cả hai trạng thái được giữ lại tại tất cả các độ dài khảo sát. Với cấu hình chính 60 s, 95.67% cửa sổ Awake và 92.99% cửa sổ Drowsy đạt yêu cầu chất lượng. Tỷ lệ giữ lại vẫn duy trì ở mức cao đối với các cửa sổ 30, 120 và 180 s, tạo cơ sở cho việc sử dụng 60 s làm cửa sổ phân tích chính và các độ dài còn lại cho đánh giá robustness.

D. Phase-Space Reconstruction

Để tái dựng không gian pha từ tín hiệu PPG một chiều, nghiên cứu sử dụng phương pháp time-delay embedding dựa trên định lý Takens [28], với hai tham số chính gồm thời gian trễ τ và số chiều nhúng m . Với chuỗi quan sát vô hướng $x(t)$, vector trạng thái trong không gian pha tái dựng được biểu diễn dưới dạng

TABLE I: Số lượng cửa sổ và tỷ lệ vượt qua kiểm soát chất lượng theo độ dài cửa sổ và trạng thái.

Window (s)	State	N	Pass (%)
30	Awake	1192	98.53
30	Drowsy	610	96.37
60	Awake	623	95.67
60	Drowsy	328	92.99
120	Awake	284	94.72
120	Drowsy	148	91.89
180	Awake	168	95.83
180	Drowsy	86	89.53


$$\mathbf{x}_i = [x_i, x_{i-\tau}, x_{i-2\tau}, \dots, x_{i-(m-1)\tau}]^T, \quad (1)$$

trong đó τ xác định khoảng trễ giữa các tọa độ và m xác định số chiều của không gian nhúng. Theo định lý Takens, trong các điều kiện thích hợp, một embedding đủ chiều có thể bảo toàn cấu trúc tô pô của attractor gốc, với điều kiện cổ điển $m \geq 2d + 1$, trong đó d là số chiều của manifold động lực học [28]. Trong nghiên cứu này, thời gian trễ được xác định bằng Average Mutual Information (AMI) [29], [30], trong khi số chiều nhúng được lựa chọn bằng phương pháp False Nearest Neighbors (FNN) [31]. Các tham số này được khảo sát trên dữ liệu Awake và Drowsy nhằm tìm một cấu hình tái dựng chung, từ đó tránh việc sử dụng các không gian pha khác nhau giữa hai trạng thái khi thực hiện các phân tích động lực học tiếp theo.


Kết quả AMI cho thấy giá trị thời gian trễ được lựa chọn tập trung trong một vùng tương đối hẹp ở cả hai trạng thái. Dựa trên phân bố quan sát được và yêu cầu sử dụng một cấu hình chung cho toàn bộ dữ liệu, $\tau = 0.16$ s được lựa chọn làm thời gian trễ cố định. Phân tích FNN cho thấy tỷ lệ false nearest neighbors giảm nhanh khi tăng số chiều nhúng và tiến tới vùng thấp ổn định ở các giá trị m lớn hơn; do đó $m = 8$ được chọn làm số chiều nhúng chung. Toàn bộ các phân tích nonlinear prediction, recurrence quantification analysis và largest Lyapunov exponent sau đó đều sử dụng cùng cấu hình $\tau = 0.16$ s và $m = 8$. Fig. 2 minh họa quá trình lựa chọn tham số và một phép chiếu ba chiều đại diện của không gian trạng thái đã được tái dựng.

E. Nonlinear Time-Series Analysis


Sau khi tái dựng không gian pha với cấu hình chung $\tau = 0.16$ s và $m = 8$, động lực học PPG được đặc trưng bằng ba nhóm phương pháp bổ sung gồm nonlinear prediction, Recurrence Quantification Analysis (RQA) và Largest Lyapunov Exponent (LLE). Ba phương pháp này được lựa chọn để khảo sát các khía cạnh khác nhau của cùng một hệ động lực học quan sát được: nonlinear prediction đánh giá khả năng dự báo ngắn hạn của sự tiến triển theo thời gian; RQA định lượng mức độ tổ chức lặp lại của quỹ đạo trong không gian trạng thái; và LLE đặc trưng mức độ phân kỳ cục bộ giữa các quỹ đạo lân cận. Việc kết hợp ba góc nhìn này cho phép mô tả sự thay đổi của PPG dynamics theo nhiều chiều thay vì phụ thuộc vào một chỉ số phi tuyến đơn lẻ. Các metric thu được từ từng phương pháp sau đó được sử dụng cho hai mục tiêu chính: kiểm định




(A) AMI-based selection of the embedding delay τ .




(B) FNN analysis for the Awake state.



(C) FNN analysis for the Drowsy state.



(D) Representative three-dimensional reconstructed state space for Awake.



(E) Representative three-dimensional reconstructed state space for Drowsy.

Fig. 2: Phase-space reconstruction of the PPG signal. (A) Average Mutual Information (AMI) was used to determine the embedding delay, leading to the common choice $\tau = 0.16$ s. (B–C) False Nearest Neighbors (FNN) analysis for the Awake and Drowsy states, respectively, with $m = 8$ selected after the proportion of false neighbors reached a low plateau. (D–E) Representative three-dimensional projections of the reconstructed state space for Awake and Drowsy using the selected embedding parameters. The same reconstruction configuration, $\tau = 0.16$ s and $m = 8$, was fixed for all subsequent nonlinear time-series analyses.

với pseudoperiodic surrogate và so sánh paired giữa trạng thái Awake và Drowsy.

1) *Nonlinear Prediction*: Khả năng dự báo ngắn hạn của động lực học PPG được đánh giá bằng phương pháp Simplex Projection [32]. Phương pháp này thực hiện dự báo trong không gian trạng thái đã tái dựng bằng cách xác định các trạng thái lân cận gần nhất của vector hiện tại và sử dụng sự tiến triển trong tương lai của các lân cận đó để ước lượng trạng thái tương lai của hệ. Toàn bộ phép dự báo sử dụng cùng cấu hình tái dựng không gian pha đã được xác định ở phần trước, với thời gian trễ $\tau = 0.16$ s và số chiều nhúng $m = 8$.

Với mỗi trạng thái truy vấn $\mathbf{x}_t$, $m + 1$ láng giềng gần nhất

hợp lệ được lựa chọn trong không gian trạng thái. Trọng số của láng giềng thứ j được xác định theo hàm suy giảm mũ của khoảng cách Euclidean:

$$w_j = \frac{\exp(-d_j/d_1)}{\sum_{k=1}^{m+1} \exp(-d_k/d_1)}, \quad (2)$$

trong đó d_j là khoảng cách từ trạng thái truy vấn đến láng giềng thứ j , còn d_1 là khoảng cách nhỏ nhất trong tập các láng giềng được chọn. Dự báo tại prediction horizon T_p sau đó được tính từ tổ hợp có trọng số của sự tiến triển tương lai của các trạng thái lân cận:




Fig. 3: Minh họa Simplex Projection trên một cửa sổ PPG đại diện. Tín hiệu quan sát được so sánh với tín hiệu dự báo tại một prediction horizon xác định trong không gian trạng thái tái dựng với $\tau = 0.16$ s và $m = 8$. Sự tương đồng giữa hai chuỗi được định lượng bằng CC, trong khi sai số dự báo được định lượng bằng NRMSE.

$$\hat{x}_{t+T_p} = \sum_{j=1}^{m+1} w_j x_{v_j+T_p}, \quad (3)$$

trong đó v_j là chỉ số thời gian của láng giềng thứ j .

Với mỗi cửa sổ PPG, quá trình dự báo được thực hiện tại nhiều prediction horizon T_p nhằm định lượng mức độ suy giảm khả năng dự báo theo thời gian. Hiệu năng dự báo được đánh giá bằng hai chỉ số bổ sung gồm hệ số tương quan (correlation coefficient, CC) và normalized root mean squared error (NRMSE). CC phản ánh mức độ tương đồng giữa chuỗi quan sát và chuỗi dự báo, trong khi NRMSE định lượng sai số dự báo đã được chuẩn hóa. Hai chỉ số được xác định lần lượt bởi

$$CC = \frac{\sum_{i=1}^N (y_i - \bar{y}) (\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^N (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2}}, \quad (4)$$

và

$$NRMSE = \frac{\sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}}{\sigma_y}, \quad (5)$$

trong đó y_i và $\hat{y}_i$ lần lượt là giá trị PPG quan sát và dự báo tại mẫu thứ i , $\bar{y}$ và $\bar{\hat{y}}$ là giá trị trung bình tương ứng, còn σ_y là độ lệch chuẩn của tín hiệu quan sát trong cửa sổ. Giá trị CC cao hơn và NRMSE thấp hơn biểu thị khả năng dự báo tốt hơn. Fig. 3 minh họa một ví dụ dự báo trên một cửa sổ PPG đại diện. Ở prediction horizon ngắn, chuỗi dự báo bám sát sự tiến triển của tín hiệu quan sát; khi T_p tăng, sai lệch giữa quỹ đạo dự báo và quỹ đạo quan sát tăng dần. Đối với mỗi cửa sổ, CC và NRMSE được tính tại từng prediction horizon và sau đó được sử dụng để đặc trưng hóa forecastability của PPG.

2) *Recurrence Quantification Analysis*: Recurrence Quantification Analysis (RQA) được sử dụng để định lượng cấu trúc lặp lại của quỹ đạo PPG trong không gian trạng thái đã tái dựng. Recurrence plot được giới thiệu như một phương pháp biểu diễn sự quay trở lại của quỹ đạo vào các vùng lân cận trong không gian trạng thái [33], [34]. Với tập các vector trạng thái $\mathbf{x}_i$, recurrence matrix được xác định bởi

$$R_{i,j} = \Theta(\varepsilon - \|\mathbf{x}_i - \mathbf{x}_j\|), \quad (6)$$

trong đó $\Theta(\cdot)$ là hàm Heaviside, ε là ngưỡng recurrence, và $\|\cdot\|$ biểu diễn khoảng cách giữa hai trạng thái trong không gian pha. Phần tử $R_{i,j} = 1$ cho biết hai trạng thái $\mathbf{x}_i$ và $\mathbf{x}_j$ được xem là recurrent, trong khi $R_{i,j} = 0$ biểu thị trường hợp ngược lại.

Trong nghiên cứu này, bốn chỉ số RQA được sử dụng để mô tả hai dạng cấu trúc chính của recurrence plot: các đường chéo và các đường thẳng đứng [34]–[36]. Các cấu trúc đường chéo được đặc trưng bởi determinism (DET) và mean diagonal line length (L_{mean}), trong khi các cấu trúc thẳng đứng được đặc trưng bởi laminarity (LAM) và trapping time (TT).

Gọi $P(l)$ là phân bố số lượng các đường chéo có độ dài l . Determinism được định nghĩa là tỷ lệ các recurrence points thuộc những đường chéo có độ dài ít nhất $l_{\min}$:

$$DET = \frac{\sum_{l=l_{\min}}^N lP(l)}{\sum_{l=1}^N lP(l)}. \quad (7)$$

DET phản ánh mức độ mà các đoạn quỹ đạo khác nhau trong không gian trạng thái tiến triển theo các mẫu tương tự trong một khoảng thời gian hữu hạn. Giá trị DET lớn cho thấy tỷ lệ lớn các recurrence points được tổ chức thành các cấu trúc đường chéo thay vì xuất hiện rời rạc [34], [35].

Độ dài trung bình của các đường chéo được xác định bởi

$$L_{\text{mean}} = \frac{\sum_{l=l_{\min}}^N lP(l)}{\sum_{l=l_{\min}}^N P(l)}. \quad (8)$$

Chỉ số L_{mean} mô tả thời gian trung bình mà hai đoạn quỹ đạo duy trì sự tiến triển tương tự trong không gian trạng thái. Do đó, các giá trị lớn hơn tương ứng với các cấu trúc đường chéo kéo dài hơn và mức độ duy trì cao hơn của trajectory similarity [34], [35].

Đối với cấu trúc thẳng đứng, gọi $P(v)$ là phân bố số lượng các đường thẳng đứng có độ dài v . Laminarity được xác định bởi

$$\text{LAM} = \frac{\sum_{v=v_{\min}}^N vP(v)}{\sum_{v=1}^N vP(v)}. \quad (9)$$

LAM biểu diễn tỷ lệ các recurrence points thuộc các cấu trúc thẳng đứng có độ dài ít nhất $v_{\min}$. Các cấu trúc này xuất hiện khi quỹ đạo duy trì gần một vùng của không gian trạng thái trong nhiều thời điểm liên tiếp, do đó LAM được sử dụng để đặc trưng mức độ laminar recurrence của hệ [34], [36].

Trapping time được định nghĩa là độ dài trung bình của các đường thẳng đứng:

$$\text{TT} = \frac{\sum_{v=v_{\min}}^N vP(v)}{\sum_{v=v_{\min}}^N P(v)}. \quad (10)$$

TT phản ánh khoảng thời gian trung bình mà quỹ đạo duy trì trong một vùng cục bộ của không gian trạng thái trước khi tiếp tục tiến triển. Vì vậy, LAM và TT cung cấp thông tin bổ sung cho các chỉ số đường chéo bằng cách mô tả mức độ laminar hoặc trapping behavior của dynamics [34], [36].

Fig. 4 minh họa recurrence plots đại diện của PPG trong hai trạng thái Awake và Drowsy. Các cấu trúc đường chéo và thẳng đứng quan sát được trên recurrence plot được định lượng tương ứng bởi $\text{DET}/L_{\text{mean}}$ và LAM/TT . Các metric này được tính độc lập cho từng cửa sổ PPG và được sử dụng trong các phân tích surrogate cũng như so sánh Awake–Drowsy tiếp theo.

3) *Largest Lyapunov Exponent*: Largest Lyapunov Exponent (LLE) được sử dụng để định lượng mức độ phân kỳ cục bộ của các quỹ đạo lân cận trong không gian trạng thái tái dựng. Trong nghiên cứu này, LLE được ước lượng bằng phương pháp của Rosenstein [37], vốn phù hợp với các chuỗi thời gian sinh lý có độ dài hữu hạn. Ý tưởng chính của phương pháp là theo dõi sự phân kỳ theo thời gian của các cặp điểm lân cận ban đầu trong không gian pha. Nếu khoảng cách ban đầu giữa hai quỹ đạo là $d_j(0)$, thì sự phân kỳ tại bước tiến hóa thứ i được xấp xỉ bởi

$$d_j(i) \approx d_j(0)e^{\lambda_1 i \Delta t}, \quad (11)$$

trong đó λ_1 là largest Lyapunov exponent và Δt là bước thời gian lấy mẫu. Lấy logarit và trung bình trên toàn bộ các cặp lân cận thu được

$$y(i) = \frac{1}{\Delta t} \langle \ln d_j(i) \rangle \approx \frac{1}{\Delta t} \langle \ln d_j(0) \rangle + \lambda_1 i, \quad (12)$$

trong đó $\langle \cdot \rangle$ biểu thị phép lấy trung bình trên tất cả các chỉ số j . Theo đó, LLE được ước lượng từ hệ số gốc của đoạn tuyến tính trong đường cong phân kỳ trung bình logarit theo thời gian tiến hóa. Giá trị LLE lớn hơn biểu thị mức độ phân kỳ cục bộ nhanh hơn giữa các quỹ đạo lân cận. Fig. 5 minh

họa một ví dụ về đường cong phân kỳ trung bình logarit và vùng fit tuyến tính dùng để ước lượng LLE. Trong nghiên cứu này, LLE được tính độc lập cho từng cửa sổ PPG và sau đó được sử dụng trong cả kiểm định surrogate lẫn so sánh Awake–Drowsy ở cấp session.

F. Pseudoperiodic Surrogate Testing

Để kiểm tra liệu tổ chức động lực học quan sát được trong tín hiệu PPG có thể được giải thích chỉ bởi một quá trình chu kỳ giả có nhiều hay không, nghiên cứu sử dụng Pseudoperiodic Surrogate (PPS) theo phương pháp của Small *et al.* [38]. PPS được lựa chọn làm mô hình null vì tín hiệu PPG có cấu trúc dao động gần chu kỳ rõ rệt; do đó một surrogate phù hợp cần bảo toàn đặc tính pseudoperiodic tổng thể của tín hiệu nhưng làm suy giảm tổ chức động lực học cục bộ trong không gian trạng thái.

Sau khi tái dựng không gian pha, surrogate được tạo bằng cách xây dựng một quỹ đạo mới thông qua các bước chuyển xác suất giữa những trạng thái lân cận. Tại trạng thái hiện tại $\mathbf{s}_i$, thay vì tiếp tục theo quỹ đạo quan sát ban đầu một cách tất định, thuật toán lựa chọn một trạng thái lân cận $\mathbf{z}_t$ làm trạng thái kế tiếp $\mathbf{s}_j$ với xác suất giảm theo khoảng cách Euclid giữa hai điểm. Xác suất chuyển trạng thái được mô tả bởi

$$P(\mathbf{s}_j = \mathbf{z}_t | \mathbf{s}_i) \propto \exp\left(-\frac{\|\mathbf{z}_t - \mathbf{s}_i\|}{\rho}\right), \quad (13)$$

trong đó $\|\mathbf{z}_t - \mathbf{s}_i\|$ là khoảng cách Euclid trong không gian trạng thái và ρ là tham số điều khiển mức độ ưu tiên các trạng thái lân cận. Khi khoảng cách giữa hai trạng thái nhỏ hơn, xác suất chuyển giữa chúng cao hơn; nhờ đó surrogate vẫn duy trì cấu trúc pseudoperiodic toàn cục của tín hiệu nhưng phá vỡ một phần quan hệ tiến triển cục bộ của quỹ đạo gốc. Fig. 6 minh họa một cửa sổ PPG đã xử lý cùng với một PPS surrogate tương ứng. Hai tín hiệu duy trì hình thái dao động gần chu kỳ tương tự, nhưng surrogate không bảo toàn chính xác sự tiến triển theo thời gian của tín hiệu gốc. Các surrogate này được sử dụng làm phân bố tham chiếu để kiểm định liệu các đặc trưng nonlinear prediction, recurrence organization và local trajectory divergence của PPG gốc có vượt quá những gì có thể được tạo ra bởi noisy pseudoperiodicity hay không.

G. Statistical Testing

Các metric phi tuyến được tính độc lập trên từng cửa sổ PPG hợp lệ và sau đó được gộp bằng trung vị trong từng cặp session–state để thu được một giá trị đại diện cho mỗi trạng thái trong mỗi session. Trung vị được sử dụng nhằm giảm ảnh hưởng của các cửa sổ ngoại lai và các phân bố metric bị lệch. Theo đó, cửa sổ đóng vai trò là đơn vị tính toán, trong khi session là đơn vị suy luận thống kê; mỗi session đóng góp một giá trị Awake và một giá trị Drowsy cho từng metric để phục vụ các so sánh paired giữa hai trạng thái.

Đối với RQ1, mỗi cửa sổ PPG gốc được so sánh với $M = 39$ pseudoperiodic surrogates trên bảy metric gồm CC, NRMSE, DET, L_{mean} , LAM, TT và LLE. Giá trị quan sát được xếp hạng cùng với các surrogate trong tập gồm $M + 1 = 40$ phần




Fig. 4: Recurrence plots đại diện của PPG trong hai trạng thái Awake và Drowsy. Các cấu trúc đường chéo được định lượng bằng DET và L_{mean} , trong khi các cấu trúc thẳng đứng được định lượng bằng LAM và TT. Figure này minh họa hình học recurrence của tín hiệu PPG; các so sánh định lượng giữa hai trạng thái được thực hiện trên các metric RQA tính tại từng cửa sổ.




Fig. 5: Minh họa ước lượng largest Lyapunov exponent bằng phương pháp Rosenstein. Đường cong biểu diễn phân kỳ trung bình logarit theo thời gian tiến hóa, trong khi đoạn gạch đứt biểu thị vùng fit tuyến tính được dùng để ước lượng hệ số góc tương ứng với LLE.

tử và được kiểm định bằng two-sided finite-sample rank test. Với hạng r , p-value được xác định bởi

$$p = \min \left(1, \frac{2 \min(r, M + 2 - r)}{M + 1} \right).$$

Với $M = 39$, độ phân giải nhỏ nhất của kiểm định là $p_{\min} = 0.05$; do đó noisy pseudoperiodic null bị bác bỏ tại $\alpha = 0.05$ khi giá trị quan sát nằm ở một trong hai extreme ranks của phân bố. Kiểm định được thực hiện ở cấp cửa sổ, và tỷ lệ cửa




Fig. 6: Minh họa một cửa sổ PPG đã xử lý và một pseudoperiodic surrogate tương ứng. PPS duy trì đặc tính dao động gần chu kỳ của tín hiệu PPG nhưng thay đổi sự tiến triển cục bộ của quỹ đạo thông qua các bước chuyển xác suất trong không gian trạng thái. Surrogate được sử dụng làm noisy pseudoperiodic null model cho kiểm định RQ1.

sổ bác bỏ null được sử dụng để đánh giá mức độ nhất quán của bằng chứng giữa các session và hai trạng thái Awake–Drowsy.

III. EXPERIMENT SETUP AND RESULTS

A. Experiment Setup

Phân tích chính được thực hiện trên processed PPG với các cửa sổ không chồng lấp có độ dài 60 s, trong khi các cửa sổ 30, 120 và 180 s được sử dụng cho robustness analysis. Chỉ các cửa sổ vượt qua cả signal quality assessment và quasi-stationarity validation mới được đưa vào phân tích. Signal quality được đánh giá trên processed PPG bằng các đoạn 5 s không chồng lấp, sử dụng hai đặc trưng gồm biên độ bền vững $A = Q_{0.95}(x) - Q_{0.05}(x)$ và mức biến thiên cục

TABLE II: Frozen nominal configuration for the primary PPG analysis pipeline.

Component	Nominal configuration
Windowing	Primary window: 60 s Non-overlapping windows Robustness: 30, 120, 180 s
Signal quality	Processed PPG; 5 s subwindows $A = Q_{0.95}(x) - Q_{0.05}(x)$ $R = \sqrt{\text{mean}((\Delta x)^2)}$ Robust session-wise z -score Artifact if $z_A > 4.5$ or $z_R > 4.5$ Reject window if any artifact sample
Quasi-stationarity	Variance stability over 10 s subwindows $v_k = \text{Var}(x_k)$, $\text{ddof} = 0$ $S = \frac{Q_{0.75}(v) - Q_{0.25}(v)}{\max(\text{median}(v), \epsilon_{\text{mach}})}$ Accept if $S \leq 0.5$
Phase-space reconstruction	Delay $\tau = 0.16$ s Embedding dimension $m = 8$ $\tau_{\text{samples}} = \text{round}(\tau f_s)$
Simplex Projection	$k = m + 1 = 9$ Euclidean distance Exponential weighting Theiler window $W = 1.0$ s 18 horizons (0.04–4.0 s) Mean CC, mean NRMSE Leave-one-out validation
RQA	Fixed $RR = 0.02$ Window-specific ϵ $W = (m - 1)\tau_{\text{samples}}$ $l_{\min} = v_{\min} = 2$ DET, L_{mean} , LAM, TT
Rosenstein LLE	Spectral-period Theiler window Fit interval: 0.80–1.30 s Follow time: 5.0 s Fit criterion: $R^2 \geq 0.90$ LLE (s^{-1})

bộ $R = \sqrt{\text{mean}((\Delta x)^2)}$, sau đó chuẩn hóa theo robust z -score trên toàn session; một đoạn được đánh dấu artifact nếu $z_A > 4.5$ hoặc $z_R > 4.5$, và cửa sổ phân tích bị loại nếu chứa bất kỳ sample nào thuộc artifact mask. Quasi-stationarity được đánh giá dựa trên độ ổn định của phương sai giữa các subwindow 10 s không chồng lấp, với chỉ số $S = [Q_{0.75}(v) - Q_{0.25}(v)] / \max(\text{median}(v), \epsilon_{\text{mach}})$ và điều kiện chấp nhận $S \leq 0.5$. Toàn bộ preprocessing, quality-control, phase-space reconstruction và estimator parameters được xác lập trước khi thực hiện so sánh Awake–Drowsy và không được tối ưu lại dựa trên p-value hoặc độ lớn hiệu ứng của các kết quả downstream. Một cấu hình tái dựng chung với $\tau = 0.16$ s và $m = 8$ được sử dụng cho tất cả các phương pháp NTSA; với từng sampling frequency, τ được chuyển sang số mẫu bằng $\text{round}(\tau f_s)$. Table II tóm tắt toàn bộ cấu hình nominal được freeze cho pipeline phân tích.

Các metric được tính trên từng cửa sổ hợp lệ và sau đó gộp ở cấp session–state, với session là đơn vị suy luận thống kê. Đối với RQA và LLE, giá trị đại diện được lấy bằng median trên các valid windows. Đối với Simplex Projection, CC và NRMSE được trung bình trên các prediction horizons trong

từng cửa sổ để thu được Mean CC và Mean NRMSE, sau đó lấy median trên các valid windows của từng session–state. So sánh Awake–Drowsy được thực hiện bằng two-sided Wilcoxon signed-rank test trên 20 paired sessions. Kết quả được báo cáo bằng median paired difference $\Delta = \text{median}(D_i - A_i)$, matched-pairs rank-biserial correlation r_{rb} , và percentile bootstrap 95% confidence interval với 20,000 resamples. Multiple comparisons được kiểm soát bằng BH–FDR trên bảy primary metrics, với $q_{\text{BH}} < 0.05$ được xem là có statistical support.

B. Dynamical Organization Beyond a Noisy Pseudoperiodic Null

Để trả lời RQ1, các đặc trưng động lực học của PPG gốc được so sánh với phân bố tham chiếu tạo bởi pseudoperiodic surrogates ở cấp cửa sổ. Nhìn chung, PPG gốc khác PPS theo một pattern nhất quán trên cả ba nhóm đặc trưng động lực học. Cụ thể, PPG gốc cho giá trị CC cao hơn và NRMSE thấp hơn, cho thấy khả năng dự báo ngắn hạn tốt hơn so với surrogate. Đồng thời, DET và L_{mean} cao hơn, phản ánh tổ chức recurrence theo đường chéo mạnh hơn, trong khi LLE cũng cao hơn, cho thấy mức độ phân kỳ cục bộ lớn hơn so với noisy pseudoperiodic null. Ngược lại, LAM và TT thấp hơn PPS, cho thấy mức độ laminar trapping thấp hơn trong tín hiệu gốc.


Fig. 7 trình bày bằng chứng định lượng cho các khác biệt này. Panel bên trái biểu diễn độ lệch giữa giá trị metric của PPG gốc và median của các PPS surrogates theo từng session, trong khi panel bên phải cho thấy tỷ lệ cửa sổ bác bỏ PPS null bằng kiểm định two-sided finite-sample rank test. Hướng thay đổi nhìn chung được duy trì ở cả hai trạng thái Awake và Drowsy, với mức độ nhất quán cao trên phần lớn session và metric.

Nhìn tổng thể, kết quả cho thấy cả Awake và Drowsy đều chứa tổ chức động lực học vượt quá những gì có thể được giải thích bởi noisy pseudoperiodicity đơn thuần. Pattern quan sát được nhất quán trên ba góc nhìn bổ sung gồm prediction, recurrence organization và local divergence. Tuy nhiên, việc bác bỏ PPS null chỉ cho phép kết luận rằng tín hiệu chứa tổ chức động lực học vượt quá mô hình null đã kiểm tra; kết quả này không được diễn giải như bằng chứng trực tiếp cho deterministic chaos.


C. Awake–Drowsy Differences in PPG Dynamics

Sau khi xác lập rằng PPG quan sát được chứa tổ chức động lực học vượt quá noisy pseudoperiodic null, RQ2 tập trung vào việc xác định cách các đặc trưng động lực học thay đổi giữa trạng thái Awake và Drowsy. Các metric được tính trên từng cửa sổ hợp lệ và sau đó được gộp bằng median trong từng cặp session–state. Do đó, mỗi session đóng góp một giá trị Awake và một giá trị Drowsy cho mỗi metric, cho phép thực hiện so sánh paired ở cấp session.

Fig. 8 trình bày các thay đổi paired của bảy metric động lực học trong cấu hình chính với cửa sổ 60 s. Phần lớn session cho thấy một pattern định hướng nhất quán gồm CC giảm, NRMSE tăng, DET giảm và LLE giảm từ Awake sang Drowsy. Các metric còn lại cho thấy L_{mean} có xu hướng giảm, trong



(A) Session-level deviation between original PPG and median PPS together with window-level PPS rejection fractions across metrics and states.



(B) Summary of the directional pattern observed for original PPG relative to the PPS null model.

Fig. 7: Results of pseudoperiodic surrogate testing. (A) Original PPG consistently deviated from the PPS ensemble across multiple nonlinear metrics, while a large fraction of windows rejected the noisy pseudoperiodic null in both Awake and Drowsy states. (B) The resulting directional pattern indicates higher forecastability, stronger diagonal recurrence organization, and greater local trajectory divergence in the original PPG, together with lower laminarity-related measures relative to PPS.

khi LAM và TT có xu hướng tăng, mặc dù mức độ nhất quán giữa các session thấp hơn.

Đối với nonlinear prediction, hai metric cho thấy sự suy giảm nhất quán của khả năng dự báo ngắn hạn khi chuyển từ Awake sang Drowsy. CC giảm với median paired difference $\Delta = -0.0339$ và bootstrap 95% CI $[-0.0595, -0.0043]$, trong khi NRMSE tăng với $\Delta = +0.0294$ và 95% CI $[0.0047, 0.0530]$. Cả hai metric vẫn được hỗ trợ sau hiệu chỉnh BH-FDR, với $q_{BH} = 0.0376$ cho CC và $q_{BH} = 0.0255$ cho NRMSE. Hai thay đổi bổ sung này cho thấy trạng thái Drowsy đi kèm với khả năng forecastability của PPG thấp hơn trong cửa sổ chính 60 s.

Các metric RQA cho thấy sự thay đổi khác nhau giữa cấu trúc recurrence theo đường chéo và cấu trúc laminar. DET giảm từ Awake sang Drowsy với median $\Delta = -0.0186$, 95% CI $[-0.0364, -0.0069]$ và $q_{BH} = 0.0376$, cho thấy mức độ tổ chức recurrence theo đường chéo giảm trong trạng thái Drowsy. L_{mean} cũng cho một paired shift theo hướng giảm ($\Delta = -0.0630$; 95% CI $[-0.1247, -0.0139]$), nhưng không còn được hỗ trợ sau hiệu chỉnh BH-FDR ($q_{BH} = 0.0816$). Ngược lại, LAM và TT có xu hướng tăng, với median $\Delta = +0.0165$ và $\Delta = +0.0095$, tương ứng. Tuy nhiên, bootstrap CI của cả hai metric đều cắt 0, và các kiểm định tương ứng không được hỗ trợ sau BH-FDR ($q_{BH} = 0.1667$ đối với LAM và $q_{BH} = 0.2024$ đối với TT).

LLE giảm rõ rệt từ Awake sang Drowsy với median paired difference $\Delta = -0.0376 \text{ s}^{-1}$ và bootstrap 95% CI $[-0.0537, -0.0230] \text{ s}^{-1}$. Effect size rank-biserial đạt $r_{rb} = -0.810$, trong khi $q_{BH} = 0.0050$. Kết quả này cho thấy các quỹ đạo lân cận trong không gian trạng thái tái dựng có mức độ phân kỳ cục bộ thấp hơn trong trạng thái Drowsy.

TABLE III: Paired Awake–Drowsy statistical comparison for the primary 60-s analysis. The paired difference is defined as $\Delta = \text{Drowsy} - \text{Awake}$.

Metric	Median Δ	95% CI	r_{rb}	q_{BH}
CC	-0.0339	$[-0.0595, -0.0043]$	-0.581	0.0376
NRMSE	+0.0294	$[0.0047, 0.0530]$	+0.667	0.0255
DET	-0.0186	$[-0.0364, -0.0069]$	-0.581	0.0376
L_{mean}	-0.0630	$[-0.1247, -0.0139]$	-0.486	0.0816
LAM	+0.0165	$[-0.0044, 0.0635]$	+0.381	0.1667
TT	+0.0095	$[-0.0034, 0.0160]$	+0.333	0.2024
LLE	-0.0376	$[-0.0537, -0.0230]$	-0.810	0.0050

Bold values indicate metrics supported after Benjamini–Hochberg false-discovery-rate correction ($q_{BH} < 0.05$).

Table III tổng hợp các paired effects, bootstrap confidence intervals, effect sizes và BH-FDR-adjusted p-values của toàn bộ bảy metric.

Trên cấu hình chính 60 s, bốn metric CC, NRMSE, DET và LLE được hỗ trợ sau hiệu chỉnh BH-FDR. Nhìn tổng thể, trạng thái Drowsy đi kèm với giảm khả năng dự báo ngắn hạn, suy giảm tổ chức recurrence theo đường chéo và giảm mức độ phân kỳ cục bộ của quỹ đạo. L_{mean} cho một paired shift theo hướng giảm, trong khi LAM và TT cho xu hướng tăng nhưng chưa nhận được hỗ trợ sau hiệu chỉnh nhiều phép kiểm định. Các kết quả này cho thấy một pattern tái tổ chức động lực học phối hợp của PPG, thay vì một thay đổi đồng nhất có thể được mô tả đơn giản theo một trục “more chaos”–“less chaos”.




Fig. 8: Paired Awake–Drowsy comparison of the seven nonlinear dynamical metrics obtained from the primary 60-s processed-PPG analysis. Each gray line connects the Awake and Drowsy values from the same session. Blue and orange markers denote Awake and Drowsy states, respectively. The panels show (a) CC, (b) NRMSE, (c) DET, (d) L_{mean} , (e) LAM, (f) TT, and (g) LLE.

D. Robustness Across Window Lengths

Để đánh giá mức độ phụ thuộc của các headline findings vào độ dài cửa sổ phân tích, bốn metric được hỗ trợ trong phân tích chính gồm CC, NRMSE, DET và LLE được kiểm tra lại trên các cửa sổ 30, 60, 120 và 180 s. Với mỗi độ dài cửa sổ, paired effect được xác định theo cùng quy ước $\Delta = \text{Drowsy} - \text{Awake}$ và được tổng hợp ở cấp session.

Fig. 9 cho thấy cả bốn metric đều giữ nguyên hướng thay đổi trên toàn bộ khoảng 30–180 s. Cụ thể, CC và DET duy trì paired effect âm, NRMSE duy trì paired effect dương, trong khi LLE tiếp tục giảm ở trạng thái Drowsy. Các cửa sổ 30 s vẫn cho cùng direction với phân tích chính nhưng có khoảng bất định rộng hơn, cho thấy mức độ biến thiên lớn hơn khi thời lượng quan sát giảm. Từ 60 đến 180 s, các effect trở nên ổn định hơn; LLE cho xu hướng giảm rõ hơn khi cửa sổ dài hơn, trong khi DET ở 180 s vẫn giữ direction nhưng có độ bất định lớn hơn.

Nhìn tổng thể, kết quả cho thấy các khác biệt động lực học chính giữa Awake và Drowsy không phụ thuộc nghiêm trọng

vào một lựa chọn duy nhất về window length. Cửa sổ 60 s cung cấp một trade-off thực tế giữa độ ngắn của đoạn tín hiệu và độ ổn định của effect, trong khi các cửa sổ 120–180 s đóng vai trò xác nhận robustness của pattern quan sát được. Việc các effect chính đã xuất hiện ở thang thời gian 60 s đồng thời hỗ trợ tính khả thi của việc đặc trưng hóa PPG dynamics trên các đoạn ghi ngắn.

E. Symbolic Dynamics for Physiological Interpretation

Bên cạnh các đặc trưng NTSA chính, symbolic dynamics được sử dụng như một lớp phân tích bổ sung nhằm hỗ trợ diễn giải sinh lý của sự chuyển đổi Awake–Drowsy. Phân tích tập trung vào ba symbolic families gồm 0V, 1V và 2V tại các cửa sổ 60, 120 và 180 s. Paired effect được xác định theo cùng quy ước $\Delta = \text{Drowsy} - \text{Awake}$ và được báo cáo theo đơn vị percentage points (pp). Table IV cho thấy 0V tăng ở cả ba độ dài cửa sổ, với median Δ lần lượt là +4.04, +2.32 và +4.58 pp tại 60, 120 và 180 s. Hướng tăng này được duy trì đồng nhất trên cả ba độ dài cửa sổ ở 17/20 session. Ngược lại, 2V giảm ở cả ba cấu hình, với median $\Delta = -0.91, -2.30$ và




Fig. 9: Robustness of the primary Awake–Drowsy effects across window lengths. Paired effects ($\Delta = \text{Drowsy} - \text{Awake}$) are shown for (a) CC, (b) NRMSE, (c) DET, and (d) LLE using 30, 60, 120, and 180 s windows. Error bars represent the corresponding 95% bootstrap confidence intervals. All four headline metrics preserve the same direction of change across window lengths, whereas the 30-s estimates exhibit greater uncertainty.

TABLE IV: Awake–Drowsy symbolic dynamics across window lengths. Paired differences are defined as $\Delta = \text{Drowsy} - \text{Awake}$.

Metric	60 s	120 s	180 s	Same direction
0V	+4.04	+2.32	+4.58	17/20
1V	+0.41	+0.03	-0.06	11/20
2V	-0.91	-2.30	-2.67	14/20

-2.67 pp, đồng thời giữ cùng hướng ở 14/20 session. Trong khi đó, 1V dao động quanh 0, có effect size nhỏ và mức độ nhất quán direction thấp hơn, với chỉ 11/20 session giữ cùng dấu trên cả ba độ dài cửa sổ.

Các point estimates không hoàn toàn giống nhau giữa các độ dài cửa sổ. Tuy nhiên, các phép so sánh trực tiếp giữa window lengths không cung cấp bằng chứng rõ ràng về sự phụ thuộc của effect vào độ dài cửa sổ: toàn bộ confidence intervals của chênh lệch r_{rb} giữa các cấu hình đều chứa 0, và điều tương tự cũng được quan sát đối với chênh lệch median Δ . Do đó, kết quả hiện tại không cho phép kết luận rằng symbolic effects thay đổi một cách có hệ thống theo window length. Theo framework symbolic dynamics của Guzzetti *et*

al., sự gia tăng 0V thường được liên hệ với tăng sympathetic modulation, trong khi sự giảm của 2V được liên hệ với giảm vagal/parasympathetic modulation. Vì vậy, pattern 0V $\uparrow$ và 2V $\downarrow$ quan sát được trong nghiên cứu này tương thích với khả năng tồn tại thay đổi trong điều hòa thần kinh tự chủ khi chuyển từ Awake sang Drowsy. Tuy nhiên, symbolic analysis chỉ được sử dụng như một lớp bằng chứng sinh lý bổ sung. Các effect không nhận được statistical support nhất quán qua toàn bộ các cấu hình, và do đó không được diễn giải như phép đo trực tiếp hoạt tính sympathetic hoặc parasympathetic. Thay vào đó, các kết quả này hỗ trợ giả thuyết rằng sự tái tổ chức động lực học của PPG quan sát được có thể đi kèm với thay đổi trong điều hòa tim mạch tự chủ.

F. Robustness to Label Definition and NTSA Parameter Choices

Để đánh giá mức độ phụ thuộc của các headline findings vào cách xác định Awake–Drowsy, bốn label rules bảo thủ hơn được xây dựng từ labeling ban đầu (P0). Hai transition-exclusion rules, T30 và T60, loại các mẫu nằm trong khoảng tương ứng ± 30 s và ± 60 s quanh mỗi điểm chuyển trạng thái trước khi phân đoạn lại thành các cửa sổ 60 s. Hai sustained-state rules, S3 và S5, chỉ giữ các episode Awake hoặc Drowsy

TABLE V: Sensitivity of the primary Awake–Drowsy effects to alternative label definitions. Values are median paired differences $\Delta = \text{Drowsy} - \text{Awake}$. P0 denotes the primary labeling; T30/T60 exclude samples within $\pm 30/\pm 60$ s of state transitions; S3/S5 retain only continuous state episodes lasting at least 3/5 min.

Metric	P0	T30	T60	S3	S5
Mean CC	-0.0339	-0.0482	-0.0251	-0.0361	-0.0337
Mean NRMSE	+0.0294	+0.0406	+0.0278	+0.0357	+0.0367
DET	-0.0186	-0.0183	-0.0167	-0.0189	-0.0213
LLE	-0.0376	-0.0322	-0.0393	-0.0344	-0.0321

TABLE VI: Sensitivity of the primary effects to phase-space reconstruction parameters. Values are median paired differences $\Delta = \text{Drowsy} - \text{Awake}$.

Metric	Delay τ (s), $m = 8$			Dimension m , $\tau = 0.16$ s		
	0.12	0.16	0.20	7	8	9
Mean CC	-0.0317	-0.0277	-0.0316	-0.0307	-0.0277	-0.0251
Mean NRMSE	+0.0321	+0.0319	+0.0296	+0.0377	+0.0319	+0.0315
DET	+0.0025	-0.0186	+0.0015	-0.0145	-0.0186	-0.0200
LLE	-0.0361	-0.0376	-0.0464	-0.0285	-0.0376	-0.0247

liên tục có thời lượng tối thiểu lần lượt 3 và 5 min. Các rule này nhằm lần lượt giảm ảnh hưởng của vùng chuyển tiếp không chắc chắn và các episode trạng thái ngắn. Toàn bộ preprocessing, quality control và cấu hình NTSA nominal được giữ nguyên; không có tham số nào được điều chỉnh lại theo kết quả Awake–Drowsy.

Cả bốn headline metrics đều giữ nguyên hướng dưới toàn bộ các label rules: Mean CC ↓, Mean NRMSE ↑, DET ↓ và LLE ↓. Trên bốn sensitivity rules, toàn bộ 16/16 paired effects giữ hướng kỳ vọng và đạt $q_{BH} < 0.05$, trong khi 14/16 bootstrap 95% confidence intervals không chứa 0. Hai trường hợp còn lại, T60–Mean CC và T30–LLE, vẫn duy trì cùng hướng effect và statistical support theo signed-rank inference. T30, T60 và S3 duy trì đủ 20 paired sessions; S5 còn 19 paired sessions do một session không còn valid Drowsy window sau khi áp dụng rule nghiêm ngặt hơn. Nhìn chung, các kết quả cho thấy những khác biệt Awake–Drowsy chính không bị chi phối chủ yếu bởi các cửa sổ gần transition hoặc các episode trạng thái ngắn trong phạm vi các label definitions đã khảo sát.

Độ nhạy đối với phase-space reconstruction được đánh giá bằng cách thay đổi riêng embedding delay và embedding dimension xung quanh cấu hình nominal ($\tau = 0.16$ s, $m = 8$). Delay được khảo sát tại $\tau = \{0.12, 0.16, 0.20\}$ s với $m = 8$ cố định, trong khi dimension được khảo sát tại $m = \{7, 8, 9\}$ với $\tau = 0.16$ s cố định. Các thay đổi được thực hiện one-factor-at-a-time và cấu hình nominal không được lựa chọn lại dựa trên p-value hoặc mức độ phân tách giữa hai trạng thái.

Mean CC, Mean NRMSE và LLE giữ nguyên hướng trên cả ba delay values, trong khi DET nhạy hơn với lựa chọn τ : effect âm xuất hiện tại cấu hình nominal nhưng tiến gần 0 và đổi dấu tại $\tau = 0.12$ và 0.20 s. Khi thay đổi embedding dimension, cả bốn headline metrics đều giữ nguyên hướng tại $m = 7, 8$ và 9,

mặc dù magnitude và statistical support thay đổi giữa các cấu hình. Verification riêng theo estimator cho kết quả tương tự: Simplex Projection ổn định quanh Theiler window nominal; DET giữ hướng dưới các perturbation của recurrence rate và RQA Theiler window; còn LLE duy trì effect âm qua các fit intervals, fit-quality thresholds và local Theiler perturbations được khảo sát. Do đó, các headline findings nhìn chung ổn định đối với label definition và phần lớn các lựa chọn NTSA hợp lý, nhưng robustness phụ thuộc vào từng metric, đặc biệt DET cho thấy sensitivity rõ hơn đối với embedding delay.

IV. DISCUSSION

Nghiên cứu này sử dụng các phương pháp phân tích chuỗi thời gian phi tuyến bổ sung cho nhau để đặc trưng động lực học PPG trên các cửa sổ ngắn khi chuyển từ Awake sang Drowsy. Kết quả cho thấy, ở cả hai trạng thái, tín hiệu PPG chứa tổ chức theo thời gian vượt quá những gì một noisy pseudoperiodic process có thể tái tạo, nhưng điều này không đồng nghĩa với bằng chứng của deterministic chaos. Đồng thời, Drowsiness đi kèm với giảm short-term forecastability, giảm tổ chức recurrence theo đường chéo và giảm local trajectory divergence, trong khi các chỉ số laminar recurrence có xu hướng tăng. Nhìn chung, các phát hiện này cho thấy quá trình Awake–Drowsy liên quan đến sự tái tổ chức đồng thời của nhiều thuộc tính động lực học khác nhau của PPG, thay vì một thay đổi đơn giản theo trục “more chaos” hay “less chaos” [39]–[42].

A. Dynamical Changes in PPG Across the Awake–Drowsy Transition

Kết quả prediction cho thấy Drowsiness đi kèm với prediction correlation thấp hơn và normalized prediction error cao hơn, tương ứng với reduced finite-horizon forecastability. Trong local prediction, các trạng thái gần nhau trong reconstructed state space được kỳ vọng tạo ra những future trajectories tương tự nếu tổ chức theo thời gian đủ ổn định. Vì vậy, kết quả hiện tại cho thấy diễn tiến của PPG trong trạng thái Drowsy khó được dự báo từ các trạng thái gần trong quá khứ hơn so với trạng thái Awake. Cách diễn giải này phù hợp với Porta et al., trong đó local prediction được sử dụng để đặc trưng short-term cardiovascular predictability và được phân biệt rõ với nonlinearity hay deterministic chaos [39]. Faes et al. cũng cho thấy predictability của cardiovascular dynamics có thể phản ánh cả self-dynamics lẫn tương tác với các hệ sinh lý khác [43]. Do đó, reduced forecastability trong Drowsiness có thể phản ánh sự thay đổi của tổ chức theo thời gian trong một regulatory configuration đang biến đổi, chứ không nhất thiết biểu thị greater complexity hoặc more chaos.

RQA cung cấp một góc nhìn hình học bổ sung. Drowsiness đi kèm với DET giảm và Lmean có xu hướng giảm, trong khi LAM và TT có xu hướng tăng. Diagonal recurrence structures phản ánh sự lặp lại của diễn tiến quỹ đạo theo thời gian, còn vertical structures phản ánh local persistence hoặc trapping trong các vùng của reconstructed state space. Các nghiên cứu RQA liên quan đến sleep trước đây đã cho thấy cardiovascular recurrence organization thay đổi theo trạng thái sinh lý [44],

trong khi Martín-González et al. cho thấy các chỉ số theo đường chéo và theo chiều dọc có thể phản ứng khác nhau và chứa các thông tin động lực học khác nhau [45]. Pattern hiện tại vì vậy phù hợp hơn với một sự tái phân bố của recurrence geometry: tổ chức theo đường chéo suy yếu trong khi laminar persistence có xu hướng tăng. DET giảm không nên được diễn giải là giảm physical determinism, và LAM/TT tăng cũng không đồng nghĩa với nonlinearity lớn hơn [41].

LLE thấp hơn trong Drowsiness cho thấy local trajectory divergence giảm trong khoảng thời gian fit. Kết quả này không nên được hiểu là “less chaos”, vì LLE phụ thuộc mạnh vào scale, embedding, data length, preprocessing và signal characteristics [42], [46]. Việc forecastability giảm đồng thời với LLE giảm cũng không phải mâu thuẫn: Simplex prediction và LLE do các thuộc tính khác nhau của dynamics và có thể nhảy với các temporal scales khác nhau [40], [42], [43]. Vì vậy, toàn bộ kết quả phù hợp với một sự thay đổi đồng thời của nhiều dynamical properties trong Awake–Drowsy transition.

B. Physiological Interpretation of the Awake–Drowsy Transition

Các thay đổi trên nên được đặt trong bối cảnh wake-to-sleep transition, thay vì xem Drowsiness như một sleep stage ổn định. Sleep onset là một quá trình chuyển tiếp có sự tái tổ chức của central nervous, autonomic, respiratory, baroreflex và cardiovascular regulation [47], [48]. Shinar et al. cho thấy wake-like và sleep-like states có thể dao động trước khi stable sleep được thiết lập [49]; Carrington et al. cho thấy repeated arousals có thể tạm thời khôi phục wake-like cardiovascular activity và làm gián đoạn quá trình settling [50]; còn Tsai et al. cho thấy cardiovascular de-arousal có thể xảy ra trước cortical N1 onset [51]. Vì vậy, Drowsiness trong dataset hiện tại phù hợp hơn với một transitional regulatory regime không ổn định hơn là stable NREM sleep.

Framework này cung cấp bối cảnh sinh lý hợp lý cho việc forecastability, recurrence geometry và local divergence cùng thay đổi. Một regulatory configuration đang thay đổi liên tục dưới ảnh hưởng của autonomic, respiratory, cardiovascular và cortical processes có thể làm biến đổi tổ chức theo thời gian của PPG. Tuy nhiên, literature hiện tại không trực tiếp chứng minh cơ chế gây ra $CC \downarrow$, $DET \downarrow$ hay $LLE \downarrow$; do đó đây vẫn là physiological interpretation, không phải causal explanation. Symbolic analysis cung cấp thêm bằng chứng hỗ trợ cho altered cardiac autonomic regulation. Pattern $0V \uparrow / 2V \downarrow$ tương tự direction được Porta et al. ghi nhận trong graded head-up tilt [52]. Tuy nhiên, nhiều nghiên cứu sleep-onset lại báo cáo xu hướng tăng vagal contribution hoặc giảm LF/HF [49], [51], [53], [54]. Sự khác biệt này không nhất thiết là contradiction, vì sleep onset có thể chứa incomplete de-arousal, repeated arousals và sự chuyển đổi không đồng bộ giữa các hệ. Do đó, symbolic result chỉ nên được xem là phù hợp với altered autonomic modulation, không phải bằng chứng trực tiếp cho một sympathetic hoặc parasympathetic shift cụ thể.

C. Ultra-Short PPG Dynamics and Practical Implications

Direction của các effects chính về forecastability, DET và LLE được bảo toàn trên các cửa sổ 30, 60, 120 và 180 s, dù 30 s có uncertainty lớn hơn. Kết quả này phù hợp với Sviridova et al., người cho thấy minimum recording length của PPG RQA phụ thuộc mạnh vào từng metric và DET ổn định sớm hơn các diagonal-length measures [26]. Điều này cũng phù hợp với kết quả hiện tại khi DET bền vững hơn Lmean. Short windows đặc biệt có ý nghĩa khi đối tượng nghiên cứu là một quá trình chuyển tiếp. Cửa sổ ngắn cải thiện temporal localization nhưng làm giảm số state-space points, recurrence structures và trajectory pairs, từ đó tăng finite-sample uncertainty. Vì vậy, 60 s nên được xem là một practical compromise cho dataset hiện tại giữa temporal resolution và estimator stability, chứ không phải một universally optimal window. Về mặt ứng dụng, các state-space properties của short-window PPG có thể cung cấp thông tin bổ sung cho conventional HR, HRV hoặc morphology features. Tuy nhiên, nghiên cứu này không xây dựng classifier và không chứng minh real-time hay early drowsiness detection. Do đó, các descriptors như forecastability, recurrence organization và local divergence nên được xem là nền tảng cho future nonlinear feature development, chứ chưa phải bằng chứng về hiệu quả của một hệ thống phát hiện.

D. Limitations

Nghiên cứu còn một số hạn chế về dữ liệu và physiological interpretation. Cohort còn nhỏ và chỉ gồm healthy young adults, vì vậy khả năng generalize sang các population khác còn hạn chế. Awake và Drowsy được xác định từ behavioral và subjective evidence thay vì PSG, nên Drowsy không thể đồng nhất với N1 hay NREM. Ngoài ra, PPG chỉ là một peripheral cardiovascular measurement, do đó các dynamical changes và symbolic patterns không thể được xem là direct measurements của sympathetic hoặc parasympathetic activity.

Các nonlinear estimates cũng phụ thuộc vào preprocessing, phase-space reconstruction, recurrence threshold, neighborhood definition, fitting interval, data length và signal quality [26], [42], [45], [46]. Nghiên cứu hiện tại đã giảm ảnh hưởng của các yếu tố này bằng frozen parameters, quality control, parameter verification và robustness analysis, nhưng không thể loại bỏ hoàn toàn finite-data và parameter dependence. Đặc biệt, các cửa sổ 30 s vẫn cho uncertainty lớn hơn.

Cuối cùng, các findings hiện tại là associations chứ không xác lập causal physiological mechanisms. Nghiên cứu chưa đồng thời đo EEG, respiration, continuous blood pressure hay direct autonomic activity, và cũng chưa có external validation trên independent dataset. Future multimodal studies và replication trên population, sensor và protocol khác sẽ cần thiết để xác định generality của các dynamical patterns hiện tại.

Tổng thể, Awake–Drowsy transition đi kèm với những thay đổi phối hợp trong PPG forecastability, recurrence organization và local trajectory divergence. Khi đặt trong bối cảnh wake-to-sleep transition, pattern này phù hợp với một quá trình tái tổ chức của peripheral cardiovascular dynamics trong một physiological regime đang chuyển tiếp và chưa ổn định, thay

vì một thay đổi đơn giản theo một trục chaos, complexity hay autonomic balance.

V. CONCLUSION

Nghiên cứu này cho thấy động lực học PPG trên các cửa sổ ngắn thay đổi có hệ thống trong quá trình chuyển từ Awake sang Drowsy. Pseudoperiodic surrogate testing cho thấy ở cả hai trạng thái, tổ chức theo thời gian của tín hiệu gốc không được tái tạo đầy đủ bởi một noisy pseudoperiodic process, nhưng kết quả này không được diễn giải như bằng chứng của deterministic chaos. Trong phân tích chính với cửa sổ 60 s, Drowsiness đi kèm với giảm short-term forecastability, giảm tổ chức recurrence theo đường chéo và giảm local trajectory divergence, được phản ánh lần lượt bởi $CC \downarrow$, $NRMSE \uparrow$, $DET \downarrow$ và $LLE \downarrow$. Các thay đổi chính này duy trì cùng direction trên các cửa sổ 30–180 s.

Nhìn tổng thể, Awake–Drowsy transition không được đặc trưng bởi một thay đổi đơn chiều của “chaos” hay “complexity”, mà bởi sự tái tổ chức phối hợp của nhiều thuộc tính động lực học bổ sung của PPG. Trong bối cảnh wake-to-sleep transition, pattern này phù hợp với sự thay đổi của peripheral cardiovascular dynamics trong một physiological regime đang chuyển tiếp và chưa ổn định. Mặc dù nghiên cứu chưa xây dựng classifier và chưa xác lập causal physiological mechanisms, các kết quả cho thấy short-window PPG chứa thông tin động lực học có thể được đặc trưng một cách nhất quán và tạo cơ sở cho các nghiên cứu tiếp theo về nonlinear physiological descriptors, multimodal validation và wearable drowsiness monitoring.

REFERENCES

- [1] O. F. Hassan, A. F. Ibrahim, M. Makhoul, B. Hafiz, and A. Gomaa, “Intelligent driver monitoring systems: a survey of drowsiness detection technologies for road safety,” *Artificial Intelligence Review*, vol. 59, no. 6, p. 137, 2026.
- [2] N. Y. Peker, E. Peker, and A. Zengin, “A comparative review of driver drowsiness detection systems: Recent advances, applications, challenges, and future directions,” *Measurement*, p. 121676, 2026.
- [3] L. El Sahmarany, M. Alkhaldi, and S. I. Alzahrani, “Sensing technologies and physiological parameters for real-time driver drowsiness detection: A comprehensive review,” *Sensors*, vol. 26, no. 11, p. 3333, 2026.
- [4] A. Amidei, P. G. Fallica, S. Conoci, and P. Pavan, “Validating photoplethysmography (ppg) data for driver drowsiness detection,” in *2021 IEEE International Workshop on Metrology for Automotive (MetroAutomotive)*, pp. 147–151, IEEE, 2021.
- [5] Y. Cao, F. Li, X. Liu, S. Yang, and Y. Wang, “Towards reliable driver drowsiness detection leveraging wearables,” *ACM Transactions on Sensor Networks*, vol. 19, no. 2, pp. 1–23, 2023.
- [6] K. Fujiwara, E. Abe, K. Kamata, C. Nakayama, Y. Suzuki, T. Yamakawa, T. Hiraoka, M. Kano, Y. Sumi, F. Masuda, et al., “Heart rate variability-based driver drowsiness detection and its validation with eeg,” *IEEE transactions on biomedical engineering*, vol. 66, no. 6, pp. 1769–1778, 2018.
- [7] Z. AlArnaout, C. Zaki, Y. Kotb, M. AlAkkoumi, and N. Mostafa, “Exploiting heart rate variability for driver drowsiness detection using wearable sensors and machine learning,” *Scientific Reports*, vol. 15, no. 1, p. 24898, 2025.
- [8] L. Yu, X. Yang, H. Wei, J. Liu, and B. Li, “Driver fatigue detection using ppg signal, facial features, head postures with an lstm model,” *Heliyon*, vol. 10, no. 21, 2024.
- [9] J. De Pedro-Carracedo, D. Fuentes-Jimenez, A. M. Ugena, and A. P. Gonzalez-Marcos, “Is the ppg signal chaotic?,” *IEEE Access*, vol. 8, pp. 107700–107715, 2020.
- [10] N. Sviridova and K. Sakai, “Human photoplethysmogram: new insight into chaotic characteristics,” *Chaos, Solitons & Fractals*, vol. 77, pp. 53–63, 2015.
- [11] P. H. Charlton, J. Allen, R. Bailón, S. Baker, J. A. Behar, F. Chen, G. D. Clifford, D. A. Clifton, H. J. Davies, C. Ding, et al., “The 2023 wearable photoplethysmography roadmap,” *Physiological measurement*, vol. 44, no. 11, p. 111001, 2023.
- [12] A. Goshvarpour and A. Goshvarpour, “Poincaré’s section analysis for ppg-based automatic emotion recognition,” *Chaos, Solitons & Fractals*, vol. 114, pp. 400–407, 2018.
- [13] F. Shoeibi, E. Najafiaghdam, and A. Ebrahimi, “Nonlinear features of photoplethysmography signals for non-invasive blood pressure estimation,” *Biomedical Signal Processing and Control*, vol. 85, p. 105067, 2023.
- [14] A. Szczesna, D. R. Augustyn, H. Josinski, K. Harezlak, A. Switonski, and P. Kasprowski, “Chaotic biomedical time signal analysis via wavelet scattering transform,” *Journal of Computational Science*, vol. 72, p. 102080, 2023.
- [15] D. Hernández-Obín, G. H. González-Gómez, A. Torres-Machorro, and C. Lerma, “Recurrence quantification analysis of photoplethysmography time series for assessing patients with peripheral artery disease,” *The European Physical Journal Special Topics*, pp. 1–19, 2026.
- [16] H. Lee, J. Lee, and M. Shin, “Using wearable ecg/ppg sensors for driver drowsiness detection based on distinguishable pattern of recurrence plots,” *Electronics*, vol. 8, no. 2, p. 192, 2019.
- [17] F. Shaffer and J. P. Ginsberg, “An overview of heart rate variability metrics and norms,” *Frontiers in public health*, vol. 5, p. 258, 2017.
- [18] F. Shaffer, Z. M. Meehan, and C. L. Zerr, “A critical review of ultra-short-term heart rate variability norms research,” *Frontiers in neuroscience*, vol. 14, p. 594880, 2020.
- [19] C. Schwarz, J. Gaspar, and R. Yousefian, “Multi-sensor driver monitoring for drowsiness prediction,” *Traffic injury prevention*, vol. 24, no. suppl, pp. S100–S104, 2023.
- [20] S. Arefnezhad, S. Samiee, A. Eichberger, and A. Nahvi, “Driver drowsiness detection based on steering wheel data applying adaptive neuro-fuzzy feature selection,” *Sensors*, vol. 19, no. 4, p. 943, 2019.
- [21] Y. Jiao, C. Zhang, X. Chen, L. Fu, C. Jiang, and C. Wen, “Driver fatigue detection using measures of heart rate variability and electrodermal activity,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 6, pp. 5510–5524, 2023.
- [22] Y. Peng, H. Deng, G. Xiang, X. Wu, X. Yu, Y. Li, and T. Yu, “A multi-source fusion approach for driver fatigue detection using physiological signals and facial image,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 11, pp. 16614–16624, 2024.
- [23] M. Awais, N. Badruddin, and M. Driberg, “A hybrid approach to detect driver drowsiness utilizing physiological signals to improve system performance and wearability,” *Sensors*, vol. 17, no. 9, p. 1991, 2017.
- [24] K. Liu, Y. Jiao, C. Du, X. Zhang, X. Chen, F. Xu, and C. Jiang, “Driver stress detection using ultra-short-term hrv analysis under real world driving conditions,” *Entropy*, vol. 25, no. 2, p. 194, 2023.
- [25] N. Sviridova, T. Zhao, K. Aihara, K. Nakamura, and A. Nakano, “Photoplethysmogram at green light: Where does chaos arise from?,” *Chaos, Solitons & Fractals*, vol. 116, pp. 157–165, 2018.
- [26] N. Sviridova, T. Zhao, A. Nakano, and T. Ikeguchi, “Photoplethysmogram recording length: defining minimal length requirement from dynamical characteristics,” *Sensors*, vol. 22, no. 14, p. 5154, 2022.
- [27] T. Åkerstedt and M. Gillberg, “Subjective and objective sleepiness in the active individual,” *International Journal of Neuroscience*, vol. 52, no. 1–2, pp. 29–37, 1990.
- [28] F. Takens, “Detecting strange attractors in turbulence,” in *Dynamical Systems and Turbulence, Warwick 1980: Proceedings of a Symposium Held at the University of Warwick 1979/80*, pp. 366–381, Springer, 1981.
- [29] A. M. Fraser and H. L. Swinney, “Independent coordinates for strange attractors from mutual information,” *Physical review A*, vol. 33, no. 2, p. 1134, 1986.
- [30] A. Kraskov, H. Stögbauer, and P. Grassberger, “Estimating mutual information,” *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, vol. 69, no. 6, p. 066138, 2004.
- [31] M. B. Kennel, R. Brown, and H. D. Abarbanel, “Determining embedding dimension for phase-space reconstruction using a geometrical construction,” *Physical review A*, vol. 45, no. 6, p. 3403, 1992.
- [32] G. Sugihara and R. M. May, “Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series,” *Nature*, vol. 344, no. 6268, pp. 734–741, 1990.

- [33] J.-P. Eckmann, S. O. Kamphorst, and D. Ruelle, "Recurrence plots of dynamical systems," *Europhysics Letters*, vol. 4, p. 973, nov 1987.
- [34] N. Marwan, M. C. Romano, M. Thiel, and J. Kurths, "Recurrence plots for the analysis of complex systems," *Physics reports*, vol. 438, no. 5-6, pp. 237–329, 2007.
- [35] C. L. Webber Jr and J. P. Zbilut, "Dynamical assessment of physiological systems and states using recurrence plot strategies," *Journal of applied physiology*, vol. 76, no. 2, pp. 965–973, 1994.
- [36] N. Marwan, N. Wessel, U. Meyerfeldt, A. Schirdewan, and J. Kurths, "Recurrence-plot-based measures of complexity and their application to heart-rate-variability data," *Physical review E*, vol. 66, no. 2, p. 026702, 2002.
- [37] M. T. Rosenstein, J. J. Collins, and C. J. De Luca, "A practical method for calculating largest lyapunov exponents from small data sets," *Physica D: Nonlinear Phenomena*, vol. 65, no. 1-2, pp. 117–134, 1993.
- [38] M. Small, D. Yu, and R. G. Harrison, "Surrogate test for pseudoperiodic time series data," *Physical Review Letters*, vol. 87, no. 18, p. 188101, 2001.
- [39] A. Porta, S. Guzzetti, R. Furlan, T. Gneccchi-Ruscione, N. Montano, and A. Malliani, "Complexity and nonlinearity in short-term heart period variability: comparison of methods based on local nonlinear prediction," *IEEE Transactions on Biomedical Engineering*, vol. 54, no. 1, pp. 94–106, 2007.
- [40] A. Porta, V. Bari, A. Marchi, B. De Maria, D. Cysarz, P. Van Leeuwen, A. C. M. Takahashi, A. M. Catai, and T. Gneccchi-Ruscione, "Complexity analyses show two distinct types of nonlinear dynamics in short heart period variability recordings," *Frontiers in Physiology*, vol. 6, p. 71, 2015.
- [41] M. Calderón-Juárez, G. H. González-Gómez, J. C. Echeverría, and C. Lerma, "Revisiting nonlinearity of heart rate variability in healthy aging," *Scientific Reports*, vol. 13, p. 13185, 2023.
- [42] J. Hu, J. Gao, and W.-w. Tung, "Characterizing heart rate variability by scale-dependent lyapunov exponent," *Chaos*, vol. 19, no. 2, p. 028506, 2009.
- [43] L. Faes, D. Marinazzo, S. Stramaglia, F. Jurysta, A. Porta, and G. Nollo, "Predictability decomposition detects the impairment of brain–heart dynamical networks during sleep disorders and their recovery with treatment," *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 374, no. 2067, p. 20150177, 2016.
- [44] J. Rolink, M. Kutz, P. Fonseca, X. Long, B. J. E. Misgeld, and S. Leonhardt, "Recurrence quantification analysis across sleep stages," *Biomedical Signal Processing and Control*, vol. 20, pp. 107–116, 2015.
- [45] S. Martín-González, J. L. Navarro-Mesa, G. Juliá-Serdá, G. M. Ramírez-Ávila, and A. G. Ravelo-García, "Improving the understanding of sleep apnea characterization using recurrence quantification analysis by defining overall acceptable values for the dimensionality of the system, the delay, and the distance threshold," *PLoS ONE*, vol. 13, no. 4, p. e0194462, 2018.
- [46] V. K. Yeragani, R. K. A. Radhakrishna, K. R. Ramakrishnan, and S. H. Srinivasan, "Measures of lfe of heart rate in different frequency bands: a possible measure of relative vagal and sympathetic activity," *Nonlinear Analysis: Real World Applications*, vol. 5, no. 3, pp. 441–462, 2004.
- [47] M. de Zambotti, J. Trinder, A. Silvani, I. M. Colrain, and F. C. Baker, "Dynamic coupling between the central and autonomic nervous systems during sleep: A review," *Neuroscience & Biobehavioral Reviews*, vol. 90, pp. 84–103, 2018.
- [48] E. Tobaldini, L. Nobili, S. Strada, K. R. Casali, A. Braghiroli, and N. Montano, "Heart rate variability in normal and pathological sleep," *Frontiers in Physiology*, vol. 4, p. 294, 2013.
- [49] Z. Shinar, S. Akselrod, Y. Dagan, and A. Baharav, "Autonomic changes during wake–sleep transition: A heart rate variability based approach," *Autonomic Neuroscience*, vol. 130, no. 1–2, pp. 17–27, 2006.
- [50] M. J. Carrington, R. Barbieri, I. M. Colrain, K. E. Crowley, Y. Kim, and J. Trinder, "Changes in cardiovascular function during the sleep onset period in young adults," *Journal of Applied Physiology*, vol. 98, no. 2, pp. 468–476, 2005.
- [51] H.-J. Tsai, T. B. J. Kuo, K.-L. Kuo, and C. C. H. Yang, "Failure to de-arouse during sleep-onset transitions in the heart rates of individuals with sleep-onset insomnia," *Journal of Psychosomatic Research*, vol. 126, p. 109809, 2019.
- [52] A. Porta, E. Tobaldini, S. Guzzetti, R. Furlan, N. Montano, and T. Gneccchi-Ruscione, "Assessment of cardiac autonomic modulation during graded head-up tilt by symbolic analysis of heart rate variability," *American Journal of Physiology-Heart and Circulatory Physiology*, vol. 293, no. 1, pp. H702–H708, 2007.
- [53] M. Carrington, M. Walsh, T. Stambas, J. Kleiman, and J. Trinder, "The influence of sleep onset on the diurnal variation in cardiac activity and cardiac control," *Journal of Sleep Research*, vol. 12, no. 3, pp. 213–221, 2003.
- [54] F. Vaussenat, A. Bhattacharya, J. Payette, A. Saidi, V. Bellemin, G.-G. Renaud-Dumoulin, S. G. Cloutier, and G. Gagnon, "Early drowsiness detection via second-order derivative analysis of heart rate variability: A non-contact ecg approach with machine learning," *Sensors*, vol. 26, no. 4, p. 1348, 2026.